Protokół badania — etap 1: prezentacja tematu

Rozpoznawanie wzorców, studia II stopnia, 2026/2027, Grupa 2 Dariusz Salzburg (103931), Filip Sejud (103928) 29.10.2026

Temat 06. Obciążenie i zmienność oceny przez walidację krzyżową. Publikacja: R. Kohavi, *A Study of Cross-Validation and Bootstrap for Accuracy Estimation and Model Selection*, IJCAI 1995. Repozytorium (kod, protokół, surowe wyniki): https://github.com/FylyppS/rozpoznawanie-wzorcow

1. Pytania badawcze i hipotezy

- **P1.** Jak liczba części k walidacji krzyżowej wpływa na obciążenie i zmienność szacowanego błędu? *H1:* $\hat{e}_{CV}$ jest obciążone pesymistycznie (zawyża błąd), najsilniej dla $k = 2$ (trening na $n/2$ obiektów), a przy $k = 10$ obciążenie jest bliskie zera; zmienność jest największa dla $k = 2$. *H1b:* efekt jest silniejszy dla niestabilnego drzewa CART niż dla stabilnego GaussianNB.
- **P2.** Co zmienia stratyfikacja przy klasie rzadkiej ($\approx 10\%$)? *H2:* stratyfikacja zmniejsza zmienność $\hat{e}_{CV}$ i eliminuje foldy bez obiektów klasy rzadkiej; wpływ na obciążenie jest niewielki.

2. Wielkości mierzone

Jednostką powtórzenia jest niezależny zbiór treningowy D_r ($r = 1, \ldots, R$), nie pojedynczy fold. Dla modelu dopasowanego na D_r i k-krotnej CV o foldach $D_{r,1}, \ldots, D_{r,k}$:

$$\hat{e}_{CV,r} = \frac{1}{k}\sum_{j=1}^{k} e_j, \qquad \text{bias}_k \approx \frac{1}{R}\sum_{r=1}^{R}\big(\hat{e}_{CV,r} - e_{test,r}\big), \qquad \text{zmienność}_k = \text{sd}_r\big(\hat{e}_{CV,r} - e_{test,r}\big),$$

gdzie e_j to odsetek pomyłek modelu uczonego na $D_r \setminus D_{r,j}$ i ocenianego na $D_{r,j}$, a $e_{test,r}$ — odsetek pomyłek modelu dopasowanego na *całym* D_r i ocenionego na dużym, niezależnym zbiorze testowym T (ocena referencyjna, przybliżenie błędu prawdziwego). Przy równych foldach średnia błędów foldów równa się ilorazowi liczby pomyłek i n (wzór Kohaviego); zapisujemy obie wartości. Podajemy też $\text{sd}_r\,\hat{e}_{CV,r}$, błąd standardowy obciążenia $\text{sd}/\sqrt{R}$, a w eksperymencie własnym czułość klasy rzadkiej i liczbę foldów bez tej klasy.

3. Generator danych (utrwalony)

$X \mid y \sim \mathcal{N}(\mu_y, I_{10})$, $\mu_1 = -\mu_0 = \frac{\delta}{2}u$, $u = (1,1,1,1,1,0,0,0,0,0)/\sqrt{5}$ (5 cech informacyjnych, 5 szumowych), $\delta = 2$ (odległość Mahalanobisa między średnimi klas), $y \sim \text{Bernoulli}(\pi_1)$. Błąd Bayesa: $\Phi(-\delta/2) = 15{,}9\%$ dla $\pi_1 = 0{,}5$; dla $\pi_1 = 0{,}1$ próg $t = \ln 9/\delta$, błąd Bayesa 7,0%, czułość klasy rzadkiej 46%. Rozkład jest zgodny z założeniami GaussianNB (model dobrze wyspecyfikowany, stabilny), a granica ukośna względem osi jest trudna dla CART (model niestabilny).

4. Odtworzenie (adaptacja)

$R = 30$ zbiorów D_r po $n = 200$ obiektów (ziarno $1000 + r$); jeden zbiór T, $N = 10\,000$ (ziarno 90001, niezależne od D_r). Modele: `GaussianNB()` i CART `DecisionTreeClassifier(random_state=0)` (bez przycinania, parametry domyślne). $k \in \{2, 5, 10\}$, `KFold(shuffle=True, random_state=`$2000 + r$`)` — te same podziały dla obu modeli.

	Kohavi (1995)	Nasza adaptacja
Dane	7 zbiorów UCI (+ losowy)	generator syntetyczny o znanym błędzie Bayesa
Modele	C4.5, Naive-Bayes (MLC++)	CART, GaussianNB (scikit-learn 1.8.0)
Punkt odniesienia	holdout na reszcie zbioru, 50 powtórzeń	duży niezależny test $N = 10\,000$, 30 powtórzeń
Metody	$k \in \{2, 5, 10, 20\}$, leave-k-out, bootstrap .632	$k \in \{2, 5, 10\}$; bez bootstrapu
Miara	trafność	odsetek pomyłek ($= 1 -$ trafność)
Stratyfikacja	wariant przy klasach zbalansowanych	osobny eksperyment z klasą rzadką 10%

5. Eksperyment własny

$\pi_1 = 0{,}1$ (ok. 20 obiektów klasy rzadkiej na 200), $R = 30$, ziarna $3000 + r$ / $4000 + r$, test T' ($N = 10\,000$, ziarno 90002). Na *tym samym* D_r: `KFold(5)` i `StratifiedKFold(5)` z tym samym ziarnem. Porównujemy obciążenie, zmienność, czułość klasy rzadkiej oraz liczbę foldów bez klasy rzadkiej (czułość nieokreślona — zapisywana jako brak wyniku z powodem).

6. Kontrola poprawności i budżet

- Duży test służy wyłącznie do oceny estymatora; nie dobieramy według niego parametrów modeli ani generatora.
- Foldy nie są niezależne: zbiory uczące sąsiednich foldów dzielą $(k-2)/(k-1)$ obiektów; niepewność liczymy po r, nie po foldach.
- Ziarna, parametry, metryki i podziały są utrwalone w `cvbias/protocol.py`; każde uruchomienie zapisuje wyniki per fold (CSV), skład klas w foldach i `meta.json` (wersje bibliotek, liczba dopasowań, czas). Zmiany protokołu odnotowujemy w raporcie.
- Budżet: odtworzenie $30 \cdot 2 \cdot (2+5+10+1) = 1080$ dopasowań, eksperyment własny $30 \cdot 2 \cdot (5+5+1) = 660$, rozdzielenie wpływu rozmiaru treningu od podziału (etap 3; model na $n(k-1)/k$ obiektach) 180 — razem $1920 \le 2500$. Próba uruchomienia (3 zbiory): 174 dopasowania w 0,16 s (CPU).