POLITECHNIKA OPOLSKA

WYDZIAŁ INFORMATYKI

KreativEU
Knowledge & Creativity European University

Obciążenie i zmienność oceny przez walidację krzyżową

Etap 1 — prezentacja tematu · temat 06, obszar: metodologia eksperymentów

R. Kohavi, A Study of Cross-Validation and Bootstrap for Accuracy Estimation and Model Selection, IJCAI 1995

Dariusz Salzburg (103931) · Filip Sejud (103928)

Rozpoznawanie wzorców, studia II stopnia, 2026/2027, grupa 2 · 29.10.2026

Publikacja i problem

Kohavi (IJCAI 1995)

- Pytanie: jak dobrze walidacja krzyżowa (CV) i bootstrap szacują trafność klasyfikatora?
- C4.5 i Naive-Bayes na 7 zbiorach UCI, 50 powtórzeń; „prawdziwa” trafność z holdoutu na reszcie zbioru
- CV zaniża trafność (pesymizm) — najbardziej dla k = 2 i 5; dla k = 10–20 prawie bez obciążenia
- Największa wariancja dla k = 2; stratyfikacja zmniejsza obciążenie i wariancję
- **Zalecenie: 10-krotna stratyfikowana CV**

Co odtwarzamy, a co zmieniamy

	Kohavi	My
Pytanie	obciążenie i wariancja CV vs k	to samo
Dane	7 zbiorów UCI	generator syntetyczny
Modele	C4.5, Naive-Bayes	CART, GaussianNB
Odniesienie	holdout, 50 powt.	test N = 10 000, 30 powt.
k	2, 5, 10, 20, LOO, bootstrap	2, 5, 10
Stratyfikacja	klasy zbalansowane	klasa rzadka 10 %

Pytanie badawcze i hipotezy

Jak liczba części walidacji krzyżowej wpływa na obciążenie i zmienność szacowanego błędu oraz co zmienia stratyfikacja przy niezbalansowanych klasach?

P1 · liczba foldów k = 2, 5, 10

- H1: ê_CV zawyża błąd (pesymizm) najbardziej dla k = 2, bo model w foldzie uczy się tylko na n/2 obiektów; dla k = 10 obciążenie bliskie zera.
- H1′: zmienność ê_CV jest największa dla k = 2.
- H1″: efekty silniejsze dla CART (model niestabilny) niż dla GaussianNB (stabilny).

P2 · stratyfikacja przy klasie rzadkiej (10 %)

- H2: stratyfikowane 5-foldowe CV ma mniejszą zmienność niż zwykłe i nie daje foldów bez klasy rzadkiej.
- H2′: obciążenie podobne — rozmiar treningu w foldzie jest taki sam.

Obciążenie i zmienność estymatora błędu

Błąd prawdziwy modelu C

$$e(C) = P(C(X) \neq Y)$$

Prawdopodobieństwo pomyłki na nowym obiekcie z tego samego rozkładu. Nieznane — przybliżamy je błędem e_test modelu na dużym, niezależnym teście T (N = 10 000).

Estymator ê_CV: obciążenie i zmienność

$$\text{bias} = \mathrm{E}[\hat{e}_{CV}] - e_{test}, \qquad \text{sd} = \sqrt{\mathrm{Var}[\hat{e}_{CV}]}$$

Obciążenie: błąd systematyczny — dodatnie = CV zawyża błąd (pesymizm). Zmienność: rozrzut ê_CV między powtórzeniami. Jedno nie wynika z drugiego.

- **Skąd pesymizm:** model w foldzie uczy się na n(k−1)/k obiektów, nie na n (k = 2: 100, k = 5: 160, k = 10: 180 z 200). Mniej danych → większy błąd.
- **Skąd zmienność:** losowy zbiór treningowy i losowy podział na foldy.
- **Jak liczymy:** 30 niezależnych zbiorów D_r → 30 różnic ê_CV,r − e_test,r; ich średnia = obciążenie, odchylenie standardowe = zmienność.

k-krotna walidacja krzyżowa: wzór i symbole

$$\hat{e}_{CV} = \frac{1}{k}\sum_{j=1}^{k} e_j, \qquad e_j = \frac{m_j}{|D_j|}$$

Symbol	Znaczenie
D = D_1 ∪ … ∪ D_k	zbiór treningowy (n = 200) podzielony losowo na k równych, rozłącznych części (foldów)
C_−j	model nauczony na wszystkich foldach poza j-tym, czyli na n(k−1)/k obiektach
m_j, e_j	liczba pomyłek modelu C_−j na odłożonym foldzie D_j i ich odsetek e_j = m_j / |D_j|
ê_CV	średnia błędów foldów; przy równych foldach = wszystkie pomyłki / n
e_test	odsetek pomyłek modelu nauczonego na całym D, zmierzony na teście T (N = 10 000)

Foldy nie są niezależnymi pomiarami: zbiory uczące C_−1 i C_−2 mają wspólne (k−2)/(k−1) obiektów (k = 10: 8 z 9). Dlatego powtórzeniem badania jest cały niezależny zbiór D_r, a nie fold.

Przykład ręczny: średnia błędów foldów (D_1, GaussianNB, k = 5)

Fold j	Obiektów w foldzie	Pomyłek	e_j = pomyłki / obiekty
1	40	7	7 / 40 = 0,175
2	40	3	3 / 40 = 0,075
3	40	7	7 / 40 = 0,175
4	40	8	8 / 40 = 0,200
5	40	4	4 / 40 = 0,100
Razem	**200**	**29**	**29 / 200 = 0,145**

Rachunek

ê_CV = (0,175 + 0,075 + 0,175 + 0,200 + 0,100**) / 5 = 0,145**

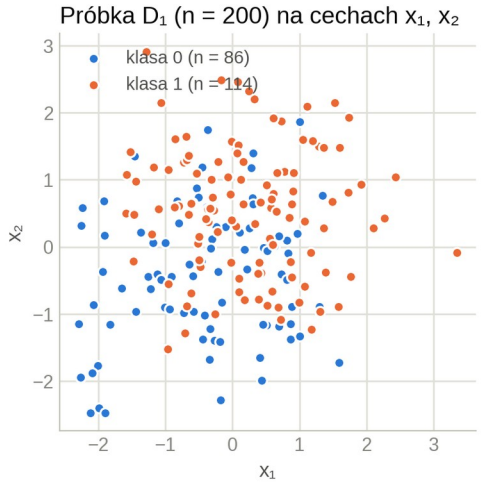
e_test = **0,1754** — GaussianNB nauczony na całym D_1 (200 obiektów), sprawdzony na T (10 000 obiektów)

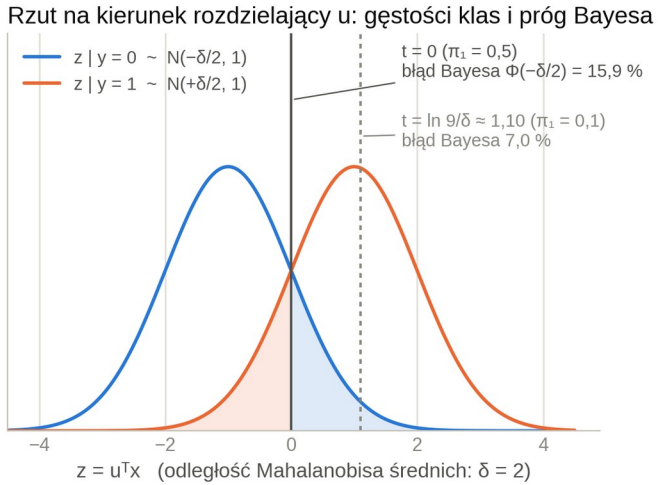
ê_CV − e_test = **−0,0304** (tu: optymizm)

- Jedna różnica nic nie mówi — zależy od losowego D_1 i losowego podziału. Dopiero średnia i rozrzut 30 takich różnic (po jednej na zbiór D_r) dają obciążenie i zmienność.
- Liczby z próby uruchomienia (results/pilot, 2026-10-25). Błąd Bayesa generatora: 15,9 % — niżej zejść się nie da.

Generator danych, powtórzenia i ocena referencyjna

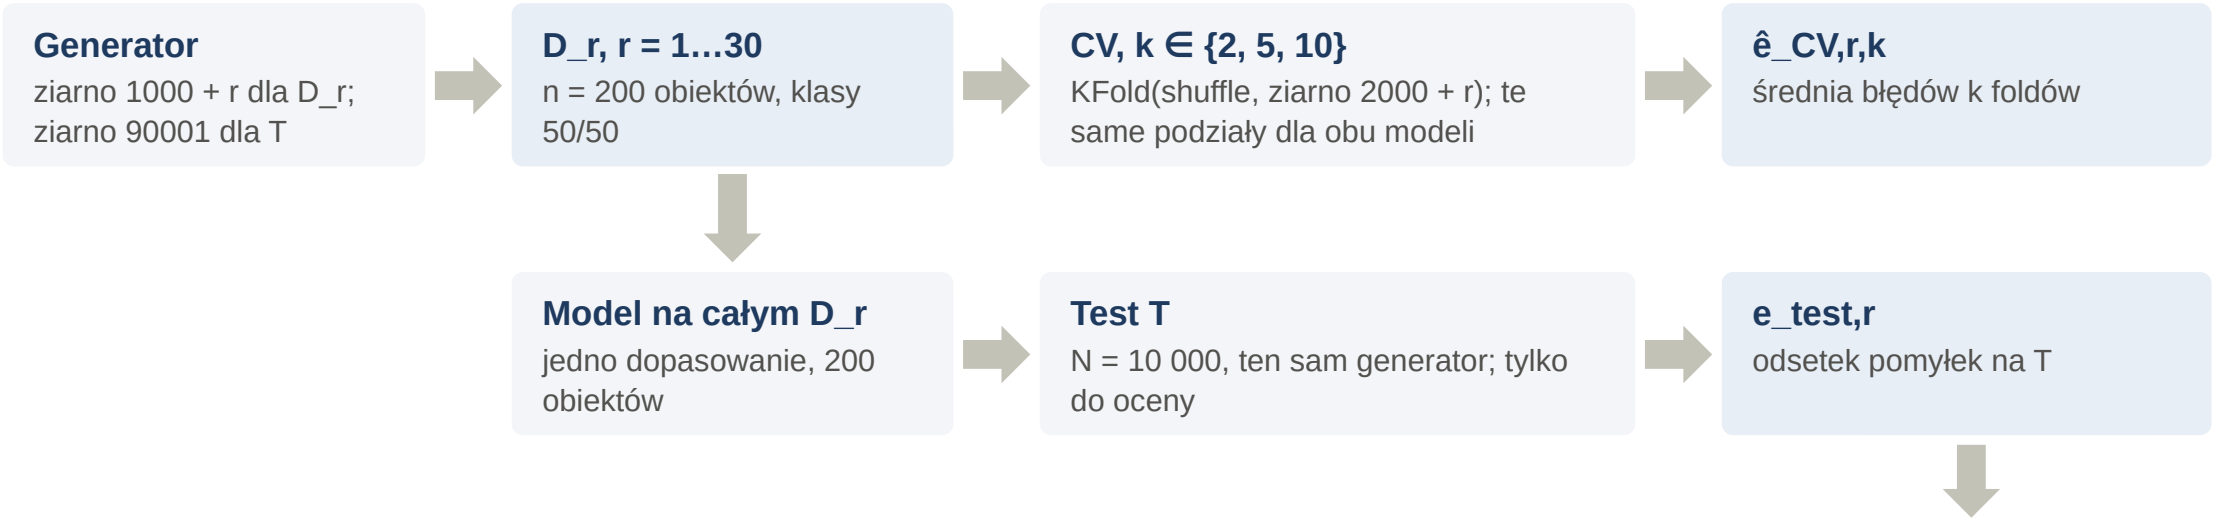
$$X \mid y \sim \mathcal{N}(\mu_y, I_{10}), \quad \mu_1 = -\mu_0 = \frac{\delta}{2}\, u, \quad u = \frac{1}{\sqrt{5}}(1,1,1,1,1,0,0,0,0,0), \quad \delta = 2$$





- **Generator:** dwie klasy normalne, 5 cech informacyjnych + 5 szumu; błąd Bayesa $\Phi(-\delta/2) = 15{,}9\ \%$ ($\pi_1 = 0{,}5$), 7,0 % dla klasy rzadkiej ($\pi_1 = 0{,}1$).
- **Powtórzenia:** R = 30 niezależnych zbiorów D_r po n = 200 obiektów (ziarno 1000 + r).
- **Ocena referencyjna:** jeden zbiór testowy T, N = 10 000, osobne ziarno — służy tylko do oceny estymatora.

Plan odtworzenia: estymata CV kontra duży test



Δ_r = ê_CV,r − e_test,r → dla każdego k i modelu 30 wartości Δ: średnia = obciążenie, odchylenie standardowe = zmienność

Modele: GaussianNB() i CART = DecisionTreeClassifier(random_state=0), parametry domyślne scikit-learn 1.8.0. **Metryka:** odsetek pomyłek. Ziarna, rozmiary i k utrwalone w **cvbias/protocol.py**.

Eksperyment własny: stratyfikacja przy klasie rzadkiej (≈ 10 %)

Plan

- Ten sam generator z $\pi_1 = 0{,}1$: ok. 20 obiektów klasy rzadkiej na 200; osobne 30 zbiorów D_r i osobny test T′ (N = 10 000).
- Na tym samym D_r: KFold(5) i StratifiedKFold(5) z tym samym ziarnem — różni się tylko przydział obiektów do foldów.
- Miary: odsetek pomyłek, czułość klasy rzadkiej, liczba foldów bez klasy rzadkiej.
- **Fold bez klasy rzadkiej → czułość nieokreślona: zapisujemy jako brak wyniku z powodem.**

Próba uruchomienia, D_1 (24 obiektów klasy rzadkiej na 200), foldy po 40

Fold	KFold: klasa rzadka w foldzie	Stratified: klasa rzadka w foldzie
1	2	4
2	5	5
3	9	5
4	6	5
5	2	5

- Już w 3 zbiorach próby: zwykły KFold dał fold bez klasy rzadkiej (2 raz), stratyfikowany — 0 razy.

Wykonalność: próba uruchomienia i kontrola poprawności

174
dopasowań w próbie
3 zbiory, oba eksperymenty

0,16 s
czas próby na CPU
zwykły laptop, bez GPU

1920 / 2500
dopasowań w pełnej serii
budżet z karty tematu

Środowisko i uruchomienie

- Python 3.14.8, numpy 2.4.4, scikit-learn 1.8.0
- python run_experiment.py --reps 3 --out results/pilot
- Zapisujemy: błąd i skład klas każdego foldu (CSV), podsumowania, meta.json z wersjami, ziarnami i liczbą dopasowań
- Kod i wyniki: github.com/FylyppS/rozpoznawanie-wzorcow

Kontrola poprawności

- Duży test tylko do oceny estymatora — nie dobieramy według niego parametrów modeli ani generatora
- Te same zbiory D_r i te same podziały dla wszystkich wariantów CV i obu modeli
- Ziarna, rozmiary, k, metryki utrwalone przed badaniem (cvbias/protocol.py)
- Brak przecieku: model w foldzie widzi tylko D ∖ D_j; T ma osobne ziarno

Ograniczenia planu, źródła i informacja o AI

Ograniczenia

- Dane syntetyczne o rozkładzie zgodnym z założeniami GaussianNB — wyniki dla NB mogą być „zbyt ładne”.
- Jeden wspólny test T dla wszystkich powtórzeń (słaba korelacja e_test,r; mała przy N = 10 000).
- R = 30 → błąd standardowy obciążenia ≈ sd/√30 (≈ 0,5 p.p.); małe efekty mogą być nieodróżnialne od zera.
- U Kohaviego „prawdziwa” trafność z holdoutu i próbki z jednego zbioru też nie są bez wad — nasz test z generatora jest czystszy.

Źródła

- R. Kohavi, A Study of Cross-Validation and Bootstrap for Accuracy Estimation and Model Selection, IJCAI 1995 — ai.stanford.edu/~ronnyk/accEst.pdf
- scikit-learn 1.8.0: KFold, StratifiedKFold, GaussianNB, DecisionTreeClassifier
- Karta tematu 06 i kontrakt przedmiotu (Moodle PO)

Informacja o AI (załącznik 2A, wariant 1)

Poziom 2 — AI jako wsparcie pracy. Narzędzie: Claude (Anthropic) w Claude Code — pomoc w analizie publikacji, szkic protokołu i kodu, redakcja slajdów. Kod uruchomiony i sprawdzony przez nas; liczby pochodzą z faktycznych obliczeń. Pełna informacja w załączonym PDF.

Slajd zapasowy: pytania kontrolne z karty tematu

Dlaczego dziesięć foldów nie daje dziesięciu niezależnych pomiarów?

Zbiory uczące kolejnych foldów pokrywają się w 8/9; każdy obiekt współtworzy 9 z 10 modeli, więc błędy foldów są skorelowane. Niezależne są dopiero powtórzenia na osobnych zbiorach D_r.

Czy niższa wariancja oznacza mniejsze obciążenie?

Nie. To osobne składowe błędu estymatora (MSE = obciążenie^2 + wariancja). Bootstrap .632 u Kohaviego: niska wariancja, obciążenie do 9,8 p.p.; leave-one-out: prawie nieobciążone, wysoka wariancja.

Czego nie wolno wybierać według dużego testu?

Parametrów modeli, parametrów generatora ani wariantu CV. Duży test ocenia estymator; każdy wybór „pod” T zamieniłby ocenę referencyjną w zbiór walidacyjny i zaniżył mierzony błąd.