POLITECHNIKA OPOLSKA

WYDZIAŁ INFORMATYKI

KreativEU
Knowledge & Creativity European University

Obciążenie i zmienność oceny przez walidację krzyżową

Etap 1 — prezentacja tematu · temat 06, obszar: metodologia eksperymentów

R. Kohavi, A Study of Cross-Validation and Bootstrap for Accuracy Estimation and Model Selection, IJCAI 1995

Dariusz Salzburg (103931) · Filip Sejud (103928)

Rozpoznawanie wzorców, studia II stopnia, 2026/2027, grupa 2 · 29.10.2026

Publikacja i problem

Kohavi (IJCAI 1995)

- Jak dobrze CV i bootstrap szacują trafność klasyfikatora?
- C4.5 i Naive-Bayes, 7 zbiorów UCI, 50 powtórzeń
- CV pesymistyczna dla k = 2 i 5; k = 10–20 prawie bez obciążenia
- Największa wariancja dla k = 2; stratyfikacja pomaga
- **Zalecenie: 10-krotna stratyfikowana CV**

Odtwarzamy: Rys. 1 i Rys. 3 (obciążenie i rozrzut vs k)

	Kohavi	My (adaptacja)
Dane	7 zbiorów UCI	generator syntetyczny
Modele	C4.5, Naive-Bayes	CART, GaussianNB
Odniesienie	holdout, 50 powtórzeń	test N = 10 000, 30 powtórzeń
k	2, 5, 10, 20, LOO, bootstrap	2, 5, 10
Bez zmian	te same foldy dla obu modeli; wiele niezależnych powtórzeń	tak samo

Pytanie badawcze i hipotezy

Jak liczba części walidacji krzyżowej wpływa na obciążenie i zmienność szacowanego błędu oraz co zmienia stratyfikacja przy niezbalansowanych klasach?

H1 Obciążenie pesymistyczne (CV zawyża błąd), największe dla k = 2, bliskie zera dla k = 10.

H1′ Zmienność największa dla k = 2.

H1″ Oba efekty silniejsze dla CART (niestabilny) niż dla GaussianNB (stabilny).

H2 Stratyfikacja przy klasie rzadkiej: mniejsza zmienność, brak foldów bez klasy rzadkiej, obciążenie podobne.

Obciążenie i zmienność estymatora błędu

Błąd prawdziwy modelu C (generalizacja)

$$e(C) = P(C(X) \neq Y)$$

Nieznany — przybliżamy go przez błąd e_{test}: model nauczony na całym D (200 obiektów), zmierzony na niezależnym teście T (10 000 obiektów).

Estymator CV i jego dwa rodzaje błędu

$$\text{bias} = \mathrm{E}[\hat{e}_{CV} - e_{test}], \qquad \text{sd}_\Delta = \text{sd}(\hat{e}_{CV} - e_{test})$$

bias > 0 = pesymizm (CV zawyża błąd) sd_Δ = odchylenie standardowe różnicy między powtórzeniami = zmienność

- **Pesymizm:** model w foldzie uczy się na n(k−1)/k obiektach — k = 2: 100, k = 5: 160, k = 10: 180 z 200.
- **Powtórzenie:** niezależny zbiór D_r, r = 1…30 → 30 różnic; ich średnia = bias, odchylenie standardowe = zmienność.
- **Niska zmienność ≠ małe obciążenie.**

k-krotna walidacja krzyżowa: wzór i symbole

$$\hat{e}_{CV} = \frac{1}{k}\sum_{j=1}^{k} e_j, \qquad e_j = \frac{m_j}{|D_j|}$$

$D = D_1 \cup \ldots \cup D_k$	zbiór treningowy (n = 200) podzielony losowo na k równych, rozłącznych foldów
C_{-j}	model nauczony bez foldu j (na n(k−1)/k obiektach), sprawdzany na odłożonym foldzie D_j
$m_j,\ e_j$	liczba pomyłek modelu C_{-j} na foldzie D_j i ich odsetek (pomyłki / rozmiar foldu)
$\hat{e}_{CV}$	średnia błędów foldów; przy równych foldach = wszystkie pomyłki / n
e_{test}	błąd modelu nauczonego na całym D, zmierzony na teście T (N = 10 000)

Foldy nie są niezależne: zbiory uczące C_{-1} i C_{-2} mają wspólne (k−2)/(k−1) obiektów (k = 10: 8 z 9).

Przykład ręczny: średnia błędów foldów (D_1, GaussianNB, k = 5)

Fold j	Obiektów w foldzie	Pomyłek m_j	$e_j = m_j / 40$
1	40	7	7 / 40 = 0,175
2	40	3	3 / 40 = 0,075
3	40	7	7 / 40 = 0,175
4	40	8	8 / 40 = 0,200
5	40	4	4 / 40 = 0,100
Razem	**200**	**29**	**29 / 200 = 0,145**

Rachunek

$$\hat{e}_{CV} = \frac{1}{5}(0{,}175 + 0{,}075 + 0{,}175 + 0{,}200 + 0{,}100)$$

$$= 0{,}725/5 = 0{,}145$$

$$e_{test} = 0{,}1754$$

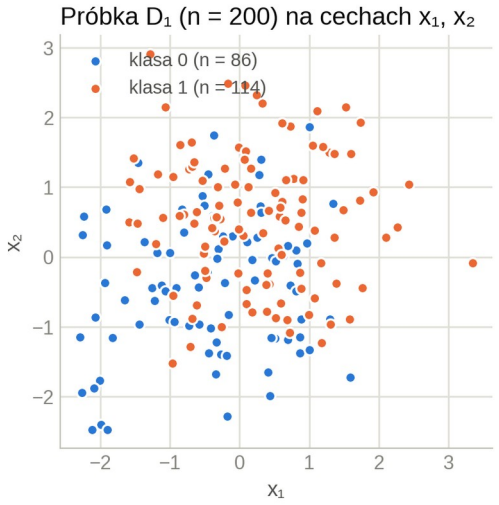
(model na całym D_1, test 10 000 obiektów)

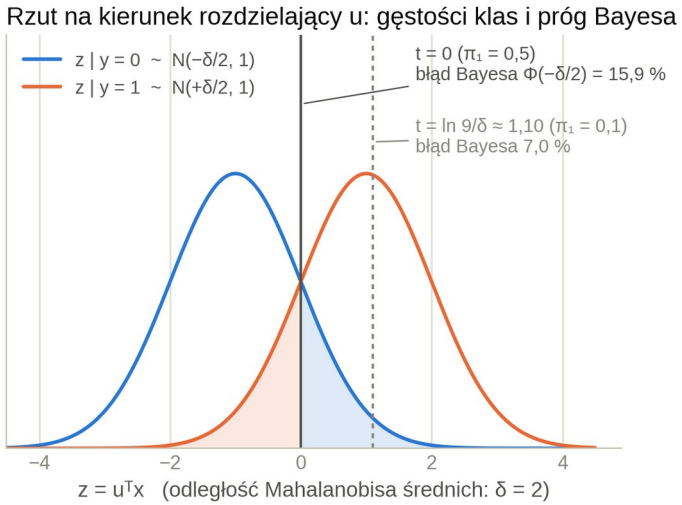
$$\hat{e}_{CV} - e_{test} = -0{,}0304$$

- Jedna różnica to przypadek — obciążenie i zmienność liczymy z 30 takich różnic (po jednej na zbiór D_r).
- Liczby z próby uruchomienia (results/pilot, 2026-10-25).

Generator danych, powtórzenia i ocena referencyjna

$$X \mid y \sim \mathcal{N}(\mu_y, I_{10}), \quad \mu_1 = -\mu_0 = \frac{\delta}{2}\, u, \quad u = \frac{1}{\sqrt{5}}(1,1,1,1,1,0,0,0,0,0), \quad \delta = 2, \quad y \sim \mathrm{Bernoulli}(\pi_1)$$





- **Generator:** dwie klasy normalne, 5 cech informacyjnych + 5 szumu; błąd Bayesa 15,9 % ($\pi_1 = 0{,}5$), 7,0 % ($\pi_1 = 0{,}1$).
- **Powtórzenia:** R = 30 zbiorów D_r po n = 200. **Ocena referencyjna:** jeden test T, N = 10 000, osobne ziarno, tylko do oceny.

Plan odtworzenia: estymata CV kontra duży test

Generator
ziarno 1000 + r dla D_r; 90001 dla T

$D_r,\ r = 1, \ldots, 30$
n = 200, klasy 50/50

CV, k ∈ {2, 5, 10}
KFold(shuffle, ziarno 2000 + r); te same podziały dla obu modeli

$\hat{e}_{CV,r,k}$
średnia błędów k foldów

Model na całym D_r
jedno dopasowanie, 200 obiektów

Test T
N = 10 000; tylko do oceny

$e_{test,r}$
odsetek pomyłek na T

$$\Delta_r = \hat{e}_{CV,r} - e_{test,r}$$

→ 30 wartości dla każdego k i modelu: średnia = obciążenie, odchylenie standardowe = zmienność

Modele: GaussianNB, CART (DecisionTreeClassifier, domyślne). **Metryka:** odsetek pomyłek. **Utrwalone w:** cvbias/protocol.py

Eksperyment własny: stratyfikacja przy klasie rzadkiej (≈ 10 %)

Plan

- Generator z $\pi_1 = 0{,}1$ → ok. 20 obiektów klasy rzadkiej na 200; 30 zbiorów, osobny test T′.
- Na tym samym D_r: KFold(5) i StratifiedKFold(5), to samo ziarno.
- Miary: odsetek pomyłek, czułość klasy rzadkiej, liczba foldów bez klasy rzadkiej.
- **Fold bez klasy rzadkiej → czułość nieokreślona → zapis jako brak wyniku z powodem.**

Próba: D_1 (24 obiektów klasy rzadkiej na 200), foldy po 40

Fold	KFold: klasa rzadka	Stratified: klasa rzadka
1	2	4
2	5	5
3	9	5
4	6	5
5	2	5

- W 3 zbiorach próby: foldy bez klasy rzadkiej — KFold 2, Stratified 0.

Wykonalność: próba uruchomienia i kontrola poprawności

174
dopasowań w próbie
3 zbiory, oba eksperymenty

0,16 s
czas próby na CPU
zwykły laptop, bez GPU

1920 / 2500
dopasowań w pełnej serii
budżet z karty tematu

Środowisko

- Python 3.14.8, scikit-learn 1.8.0
- Zapisujemy błąd i skład klas każdego foldu, podsumowania, meta.json (wersje, ziarna, liczba dopasowań)
- github.com/FylyppS/rozpoznawanie-wzorcow

Kontrola poprawności

- Duży test tylko do oceny — nic według niego nie dobieramy
- Te same zbiory i podziały dla wszystkich wariantów CV i obu modeli
- Ziarna, rozmiary, k, metryki utrwalone przed badaniem
- Brak przecieku: model w foldzie widzi tylko $D \setminus D_j$

Ograniczenia planu i źródła

Ograniczenia

- Dane „idealne” dla GaussianNB (rozkład zgodny z jego założeniami).
- Jeden wspólny test T dla wszystkich powtórzeń.
- R = 30: efekty poniżej ok. 1 p.p. nieodróżnialne od zera.
- Kohavi: „prawda” z holdoutu; próbki z jednego zbioru; Propozycja 1 zakłada stabilny model.

Źródła

- R. Kohavi, A Study of Cross-Validation and Bootstrap for Accuracy Estimation and Model Selection, IJCAI 1995 — ai.stanford.edu/~ronnyk/accEst.pdf
- scikit-learn 1.8.0: KFold, StratifiedKFold, GaussianNB, DecisionTreeClassifier
- Karta tematu 06 i kontrakt przedmiotu (Moodle PO)
- Kod, protokół i surowe wyniki: github.com/FylyppS/rozpoznawanie-wzorcow