Notatka z postępów — etap 2: wstępne wyniki

Rozpoznawanie wzorców, studia II stopnia, 2026/2027, Grupa 2 Dariusz Salzburg (103931), Filip Sejud (103928) listopad 2026

Temat 06. Obciążenie i zmienność oceny przez walidację krzyżową (R. Kohavi, IJCAI 1995). Repozytorium z kodem, instrukcją uruchomienia i surowymi wynikami: https://github.com/FylyppS/rozpoznawanie-wzorcow; wyniki etapu 2 w `results/etap2/`.

1. Stan prac

- Uruchomiono pełny potok badania na **pierwszych 10 z 30** niezależnych zbiorów treningowych ($D_1, \ldots, D_{10}$; ziarna $1000+r$, takie same jak w utrwalonym protokole, więc będą to pierwsze zbiory pełnej serii): odtworzenie ($k \in \{2, 5, 10\}$, GaussianNB i CART) oraz eksperyment własny (klasa rzadka $\pi_1 = 0{,}1$, KFold(5) vs StratifiedKFold(5)). Łącznie 580 dopasowań w 0,53 s (CPU); pełna seria: $1920 \leq 2500$.
- Polecenia: `python run_experiment.py -reps 10 -out results/etap2` i `python make_figures_etap2.py`. Zapisywane są: błąd i skład klas każdego foldu (`*_folds.csv`), podsumowania per zbiór × model × wariant CV (`*_summary.csv`: $\hat{e}_{CV}$, e_{test}, Δ) oraz `meta.json` (wersje, ziarna, liczba dopasowań, czas).
- **Bez zmian protokołu.** Jedyna zmiana środowiska: Python 3.14.10 zamiast 3.14.8 (po aktualizacji systemu); wersje bibliotek są przypięte (`requirements.txt`: scikit-learn 1.8.0, numpy 2.4.4). Zbiór D_1 dał liczby identyczne z próbą z etapu 1 (pomyłki foldów 7, 3, 7, 8, 4; $e_{test} = 0{,}1754$), co potwierdza odtwarzalność.

2. Co jest powtórzeniem badania i gdzie występują zależności

Powtórzeniem jest **niezależny zbiór treningowy** D_r. Dla każdego D_r, modelu i k obliczamy jedną różnicę $\Delta_{r,k} = \hat{e}_{CV,r,k} - e_{test,r}$, gdzie $\hat{e}_{CV} = \frac{1}{k}\sum_j e_j$ to średnia błędów foldów, a $e_{test,r}$ — błąd modelu dopasowanego na całym D_r i ocenionego na wspólnym teście T ($N = 10\,000$, osobne ziarno). Obciążenie szacujemy średnią Δ po r, zmienność — odchyleniem standardowym Δ po r, a niepewność obciążenia błędem standardowym $\mathrm{sd}/\sqrt{R}$. Zależności: (a) błędy foldów w jednym D_r — zbiory uczące sąsiednich foldów dzielą $(k-2)/(k-1)$ obiektów (8 z 9 dla $k = 10$), dlatego fold nie jest powtórzeniem i nie liczymy z foldów niepewności; (b) $\hat{e}_{CV}$ dla $k = 2, 5, 10$ i dla obu modeli liczone są na tym samym D_r i tych samych podziałach (ziarno $2000+r$) — porównania są sparowane, ale nie zwiększają liczby niezależnych prób; (c) KFold i StratifiedKFold w eksperymencie własnym dzielą ten sam D_r i to samo ziarno; (d) wszystkie $e_{test,r}$ dzielą szum jednego testu T (ok. 0,4 p.p., pomijalny, odnotowany). Niezależne są wyłącznie zbiory D_r między sobą.

3. Pierwsze wyniki — odtworzenie (10 zbiorów)

Model	k	obciążenie (średnia Δ)	błąd std.	zmienność (sd Δ)	średnie $\hat{e}_{CV}$	średnie e_{test}
GaussianNB	2	+1,4 p.p.	1,0 p.p.	3,2 p.p.	18,6 %	17,2 %
	5	−0,1 p.p.	0,9 p.p.	2,8 p.p.	17,1 %	17,2 %
	10	−0,2 p.p.	0,8 p.p.	2,5 p.p.	17,0 %	17,2 %
CART	2	+1,2 p.p.	1,7 p.p.	5,3 p.p.	29,6 %	28,4 %
	5	+0,9 p.p.	1,4 p.p.	4,3 p.p.	29,3 %	28,4 %
	10	+1,7 p.p.	1,3 p.p.	4,1 p.p.	30,1 %	28,4 %

Punkt odniesienia: e_{test} dla GaussianNB jest niemal stałe między zbiorami (sd 0,4 p.p.; błąd Bayesa 15,9 %), dla CART waha się od 23,9 do 33,5 % (sd 2,8 p.p.) — niestabilny model daje inny klasyfikator na każdym zbiorze i jest daleko od optimum (drzewo bez przycinania). Wykres różnic Δ_r (`etap2/figures/diff_strip.png`) oraz zestawienie metody i punktu odniesienia dla każdego D_r (`cv_vs_test.png`) są w slajdach. Przykład sprawdzalny ręcznie: D_1, GaussianNB, $k = 5$: $\hat{e}_{CV} = (0{,}175 + 0{,}075 + 0{,}175 + 0{,}200 + 0{,}100)/5 = 0{,}145$, $e_{test} = 1754/10\,000 = 0{,}1754$, $\Delta = -0{,}030$.

4. Pierwsze wyniki — eksperyment własny (stratyfikacja, 10 zbiorów)

W zbiorach było 14–27 obiektów klasy rzadkiej na 200. KFold rozrzucał je po foldach testowych w zakresie 0–9, StratifiedKFold 2–6. Obciążenie: GaussianNB +1,2 vs +0,9 p.p., CART +0,5 vs +0,7 p.p. (KFold vs Stratified; błędy standardowe 0,5–1,2 p.p.). Zmienność: GaussianNB 2,0 → 1,6 p.p., CART 3,9 → 2,9 p.p.. Jeden fold bez klasy rzadkiej (KFold, D_3 z 14 obiektami klasy rzadkiej, fold 3) — czułość nieokreślona, zapisana jako brak wyniku z powodem (flaga w CSV); stratyfikacja: 0 takich foldów. Czułość klasy rzadkiej na teście: GaussianNB 41 %, CART 35 % (klasyfikator Bayesa: 46 %).

5. Wstępna interpretacja (bez wniosków końcowych)

- **H1** (pesymizm malejący z k): dla GaussianNB zgodne z Kohavim — +1,4 p.p. przy $k = 2$, ≈ 0 przy $k = 5$ i 10 (Propozycja 1: stabilny model ⇒ CV nieobciążona). Dla CART wszystkie średnie są dodatnie, ale przy błędach standardowych 1,3–1,7 p.p. zależność od k jest nierozstrzygnięta.
- **H1′** (zmienność największa dla $k = 2$): zgodne dla obu modeli; **H1″**: zmienność CART ok. 1,6× większa niż GaussianNB; o obciążeniu nie da się jeszcze powiedzieć.
- **H2**: stratyfikacja zmniejsza zmienność (oba modele), obciążenie podobne, usuwa foldy bez klasy rzadkiej — zgodne z obserwacją Kohaviego, że stratyfikacja jest „jednolicie lepsza".

6. Ograniczenia, problemy, plan

Ograniczenia: 10 zbiorów (błąd standardowy obciążenia 0,8–1,7 p.p.; przy 30 spadnie ok. 1,7 raza); jeden wspólny test T; CART w domyślnej konfiguracji silnie przeuczony; dane zgodne z założeniami GaussianNB. Problemy: brak — żadnych odrzuconych uruchomień; jedyne zdarzenie to fold bez klasy rzadkiej, obsłużony zgodnie z kartą. Plan do etapu 3: dokończyć serię i eksperyment własny ($D_{11} \ldots D_{30}$, 1160 dopasowań), dodać pomiar rozdzielający wpływ rozmiaru treningu od losowego podziału (model na 100/160/180 obiektach z D_r oceniony na T; 180 dopasowań), raport 6–8 stron. Razem $580 + 1340 = 1920 \leq 2500$; protokół bez zmian.