Obciążenie i zmienność oceny przez walidację krzyżową

Etap 2 — wstępne wyniki · temat 06, obszar: metodologia eksperymentów

R. Kohavi, A Study of Cross-Validation and Bootstrap for Accuracy Estimation and Model Selection, IJCAI 1995

Dariusz Salzburg (103931) · Filip Sejud (103928)

Rozpoznawanie wzorców, studia II stopnia, 2026/2027, grupa 2

Przypomnienie: pytanie, hipotezy, protokół

Pytanie (karta tematu)

Jak liczba foldów k wpływa na obciążenie i zmienność błędu szacowanego przez CV i co zmienia stratyfikacja przy klasie rzadkiej?

Hipotezy

- H1 CV zawyża błąd (pesymizm), najbardziej dla k = 2, prawie wcale dla k = 10
- H1′ zmienność największa dla k = 2
- H1″ oba efekty silniejsze dla CART niż dla GaussianNB
- H2 stratyfikacja: mniejsza zmienność, brak foldów bez klasy rzadkiej, obciążenie podobne

Protokół (utrwalony na etapie 1)

- Generator: 2 klasy normalne, 10 cech (5 informacyjnych), δ = 2; błąd Bayesa 15,9 % (π_1 = 0,5), 7,0 % (π_1 = 0,1)
- R = 30 zbiorów D_r po n = 200; jeden test T, N = 10 000 (osobne ziarno, tylko do oceny)
- Modele: GaussianNB, CART (DecisionTreeClassifier, domyślne); k ∈ {2, 5, 10}; te same foldy dla obu modeli
- Mierzone: $\Delta_r = \hat{e}_CV,r - e_test,r \rightarrow$ średnia = obciążenie, sd = zmienność
- Eksperyment własny: π_1 = 0,1; KFold(5) vs StratifiedKFold(5) na tym samym D_r

Stan prac: uruchamialny kod i pierwsze wyniki

10 / 30

niezależnych zbiorów D_r

pierwsze powtórzenia serii

580

dopasowań modeli

0,53 s na CPU; pełna seria 1920 ≤ 2500

0

zmian protokołu

stałe z etapu 1 w cvbias/protocol.py

Uruchomienie (README)

python run_experiment.py --reps 10 --out results/etap2
python make_figures_etap2.py

Zapis każdego uruchomienia:

- *_folds.csv — błąd i skład klas każdego foldu
- *_summary.csv — ê_CV, e_test, Δ dla zbioru × modelu × k
- meta.json — wersje, ziarna, liczba dopasowań, czas

Kontrola poprawności w kodzie

- Test T losowany raz, z własnego ziarna — nic według niego nie dobieramy
- Ziarno podziału zależy tylko od r → te same foldy dla obu modeli i (w eksperymencie własnym) obu wariantów CV
- Każde dopasowanie = świeży model; licznik dopasowań pilnuje budżetu
- Fold bez klasy rzadkiej → czułość NaN + flaga w CSV (nie zero)
- Środowisko: Python 3.14.10, scikit-learn 1.8.0, numpy 2.4.4

Co jest powtórzeniem badania

Generator

ziarno 1000 + r

D_r

200 obiektów, niezależny od innych D_r i od T

$\hat{e}_{CV,r,k}$

$e_{test,r}$

góra: CV (k = 2, 5, 10) na D_r; dół: model na całym D_r, błąd na T

$\Delta_{r,k} = \hat{e}_{CV,r,k} - e_{test,r}$

jedna liczba na (r, k, model)

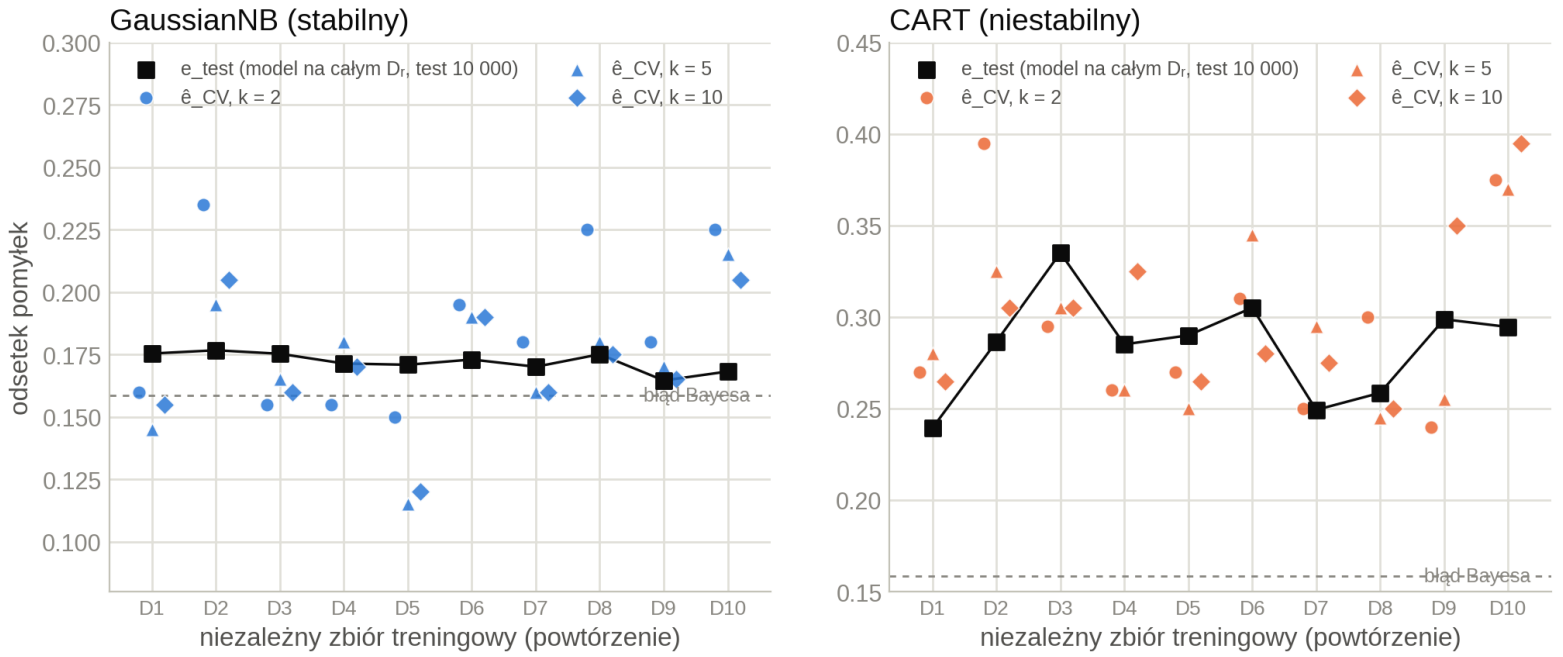
Powtórzenie = cały niezależny zbiór treningowy D_r (karta tematu), nie fold i nie podział.

- Dla każdego k i modelu mamy dziś 10 niezależnych wartości Δ_r (docelowo 30): ich średnia szacuje obciążenie, odchylenie standardowe — zmienność.
- Niepewność obciążenia liczymy po r: błąd standardowy = sd(Δ)/√10 — nigdy z rozrzutu między foldami.
- Każda inna liczba na wykresach (ê_CV, e_test, Δ) to wynik dla jednego konkretnego D_r — pojedyncza realizacja, nie wynik badania.

Gdzie występują zależności (i co z nimi robimy)

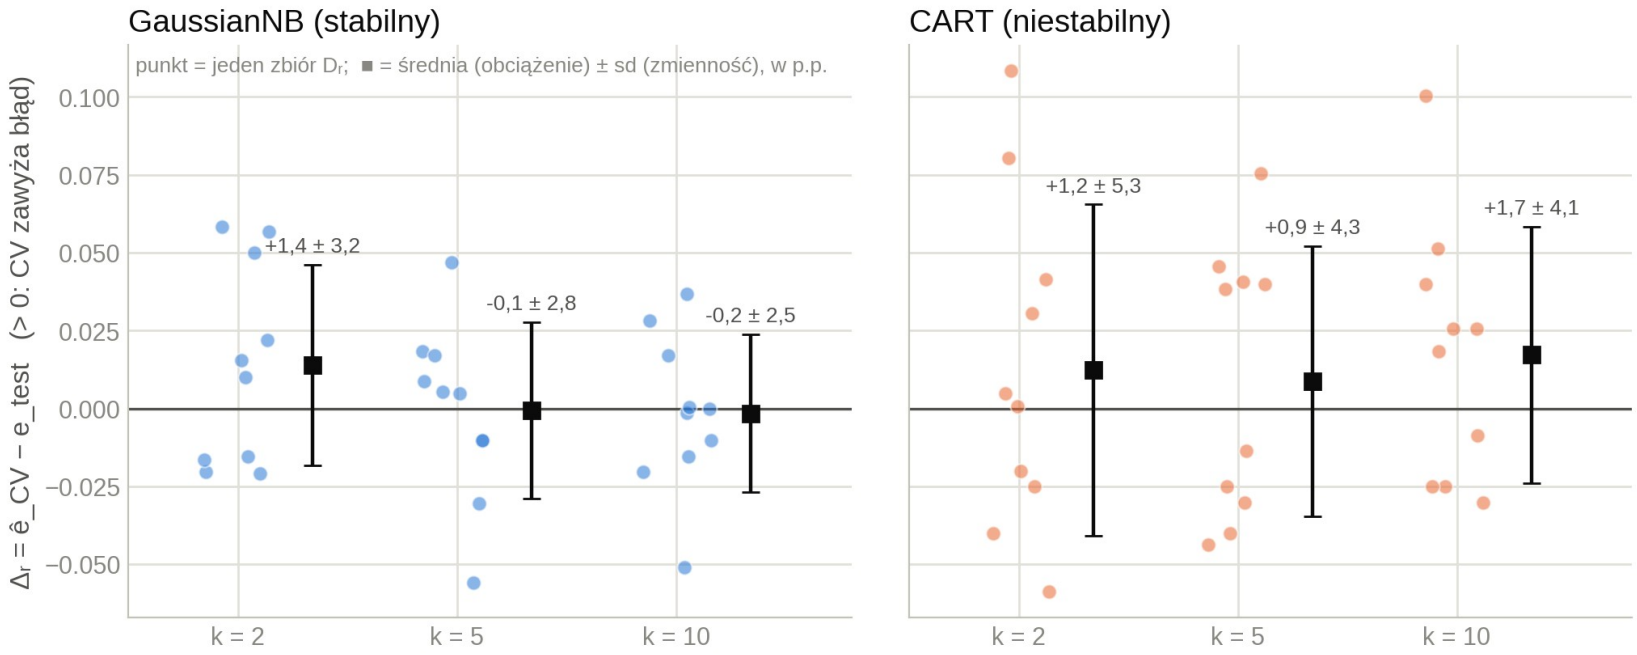
Między czym	Skąd zależność	Skutek / co robimy
błędami foldów $e_1 \ldots e_k$ w jednym D_r	zbiory uczące sąsiednich foldów dzielą (k−2)/(k−1) obiektów (k = 10: 8 z 9)	nie liczymy niepewności z foldów; fold nie jest powtórzeniem
$\hat{e}$_CV dla k = 2, 5, 10 na tym samym D_r	ten sam zbiór, ta sama prawda e_test,r	porównania między k są sparowane (zalecane: te same próbki); nie są to niezależne próby
GaussianNB i CART	te same D_r i te same foldy (jak u Kohaviego)	różnica między modelami nie wynika z innego losowania
KFold i StratifiedKFold (eksp. własny)	ten sam D_r, to samo ziarno — różni się tylko przydział do foldów	efekt stratyfikacji liczymy jako różnicę w parach
e_test,r dla różnych r	jeden wspólny test T	wspólny szum testu ≈ 0,4 p.p. — pomijalny, odnotowany
D_r dla różnych r	osobne ziarna 1000 + r, niezależne od T	JEDYNA niezależność — po niej liczymy średnią i sd

Wynik metody i punktu odniesienia dla każdego zbioru D_r



Czarne kwadraty = e_test,r (punkt odniesienia): GaussianNB 17,2 % ± 0,4 p.p., CART 28,4 % ± 2,8 p.p.; błąd Bayesa 15,9 %. Kolorowe = ê_CV (metoda) dla k = 2, 5, 10.

Wykres różnic $\Delta_r = \hat{e}_CV - e_test$ (pierwsze 10 zbiorów)



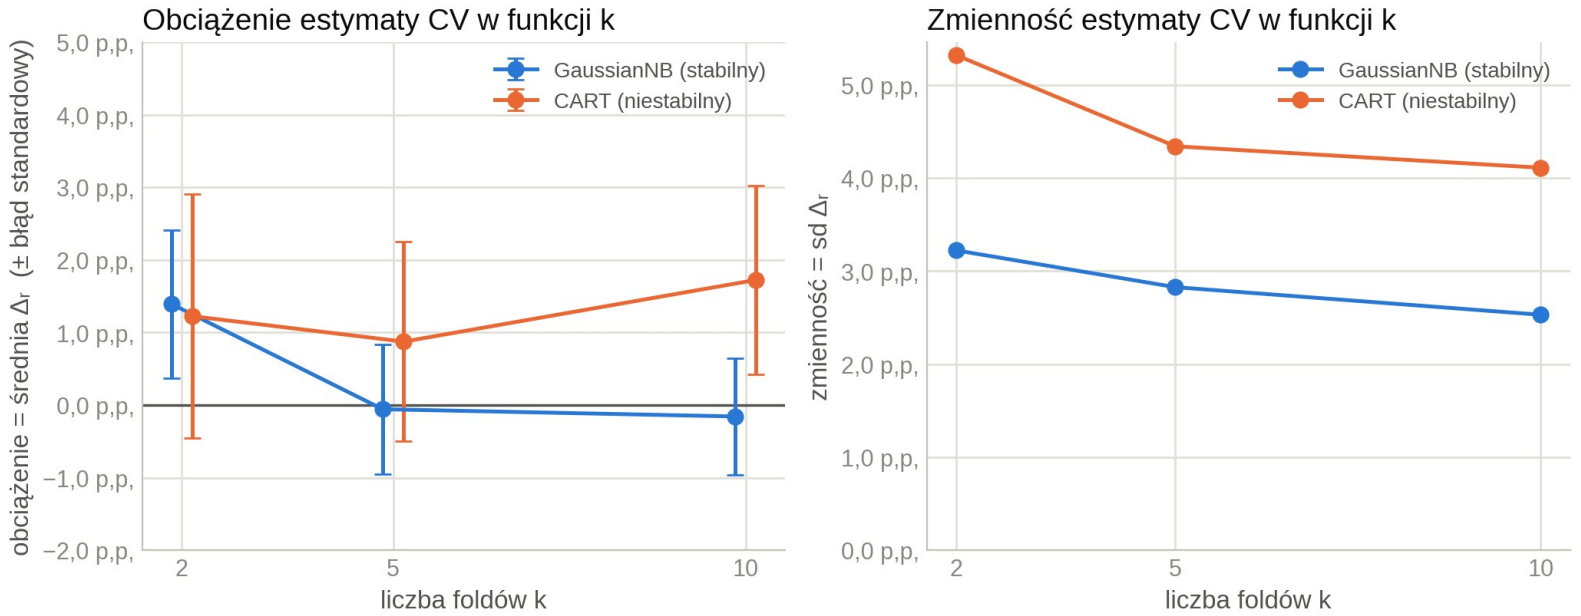
Każdy punkt = jeden niezależny zbiór D_r. Czarny kwadrat = średnia Δ (obciążenie), wąsy = ± odchylenie standardowe (zmienność). Dodatnie Δ = CV zawyża błąd (pesymizm).

Obciążenie i zmienność na 10 zbiorach (odtworzenie)

Model	k	obciążenie (średnia Δ)	błąd standardowy	zmienność (sd Δ)	średnie ê_CV	średnie e_test
GaussianNB	2	+1,4 p.p.	1,0 p.p.	3,2 p.p.	18,6 %	17,2 %
	5	−0,1 p.p.	0,9 p.p.	2,8 p.p.	17,1 %	17,2 %
	10	−0,2 p.p.	0,8 p.p.	2,5 p.p.	17,0 %	17,2 %
CART (DecisionTreeClassifier)	2	+1,2 p.p.	1,7 p.p.	5,3 p.p.	29,6 %	28,4 %
	5	+0,9 p.p.	1,4 p.p.	4,3 p.p.	29,3 %	28,4 %
	10	+1,7 p.p.	1,3 p.p.	4,1 p.p.	30,1 %	28,4 %

Jak czytać: obciążenie „istotnie” różne od zera dopiero, gdy |średnia| > ok. 2 błędy standardowe. Po 10 zbiorach żadna kombinacja nie przekracza tego progu; najbliżej jest GaussianNB przy k = 2 (+1,4 ± 1,0 p.p.). Zmienność (sd) maleje z k dla obu modeli; dla CART jest ok. 1,6× większa niż dla GaussianNB.

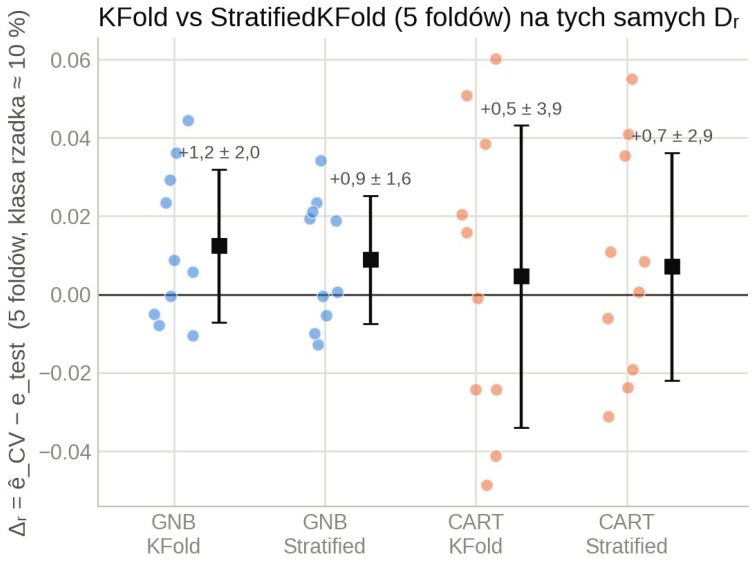
Fragment odtworzenia: obciążenie i zmienność vs k

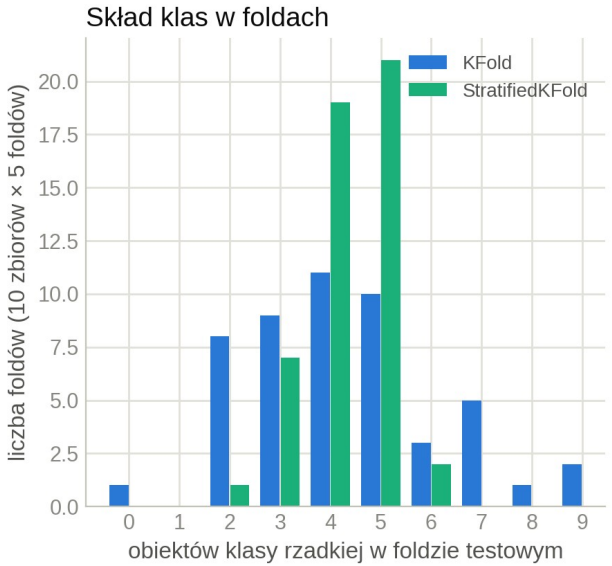


Pierwsze 10 z 30 niezależnych zbiorów treningowych; błąd standardowy obciążenia = sd/√10.

Kohavi (C4.5, Naive-Bayes, zbiory UCI): pesymizm największy dla k = 2 i 5, prawie zerowy dla k = 10–20; wariancja największa dla k = 2. U nas po 10 zbiorach: zmienność maleje z k (oba modele); obciążenie k = 2 > 0 widać dla GaussianNB, dla CART niepewność za duża.

Eksperyment własny: stratyfikacja (pierwsze wyniki)





	KFold	Stratified
GaussianNB: obciążenie	+1,2 p.p.	+0,9 p.p.
GaussianNB: zmienność	2,0 p.p.	1,6 p.p.
CART: obciążenie	+0,5 p.p.	+0,7 p.p.
CART: zmienność	3,9 p.p.	2,9 p.p.
foldy bez klasy rzadkiej	1	0
klasa rzadka w foldzie (min–max)	0–9	2–6

Zbiór D_3 ma 14 obiektów klasy rzadkiej; zwykły KFold dał fold bez tej klasy → czułość 0/0 zapisana jako brak wyniku z powodem.

Czułość klasy rzadkiej na teście: GaussianNB 41,0 %, CART 35,2 % (Bayes: 46 %).

Wstępna interpretacja względem hipotez (10 z 30 zbiorów)

Hipoteza	Co widać po 10 zbiorach	Status
H1 pesymizm, największy dla k = 2, ≈ 0 dla k = 10	GaussianNB: +1,4 → −0,1 → −0,2 p.p. · CART: dodatnie, ale se 1,3–1,7 p.p.	zgodne dla NB; CART nierozstrzygnięte
H1′ zmienność największa dla k = 2	sd maleje z k: NB 3,2 → 2,5, CART 5,3 → 4,1 p.p.	zgodne
H1″ efekty silniejsze dla CART	zmienność CART ≈ 1,6× NB; obciążenie — za duża niepewność	zgodne dla zmienności
H2 stratyfikacja: mniejsza zmienność, brak foldów bez klasy, obciążenie podobne	sd 2,0 → 1,6 (NB), 3,9 → 2,9 (CART); foldy bez klasy 1 → 0	zgodne

To są wyniki wstępne: na 10 zbiorach błąd standardowy obciążenia wynosi 0,8–1,7 p.p., więc efekty rzędu 1 p.p. są nieodróżnialne od zera. Wynik negatywny (np. brak pesymizmu CART) nie będzie porażką — kontrakt §6.

Ograniczenia wyników wstępnych i problemy

Ograniczenia

- 10 zbiorów: błąd standardowy obciążenia 0,8–1,7 p.p.; przy 30 spadnie ok. 1,7 raza — nadal efekty < 1 p.p. mogą być niewidoczne
- Jeden wspólny test T (szum 0,4 p.p. wspólny dla wszystkich e_test)
- CART bez przycinania jest daleko od błędu Bayesa (28 % vs 16 %) — wyniki dotyczą „przeuczonego drzewa”, nie drzew w ogóle
- Dane idealne dla GaussianNB — jego nieobciążoność może być „zbyt ładna”
- Nie rozdzieliliśmy jeszcze wpływu rozmiaru treningu od losowego podziału (etap 3)

Problemy i odstępstwa

- Zmiana środowiska: Python 3.14.10 (etap 1: 3.14.8), te same wersje bibliotek; wyniki dla D_1 identyczne z próbą z etapu 1
- Jeden fold bez klasy rzadkiej (KFold, D_3) — zgodnie z kartą zapisany jako brak wyniku z powodem; średnia czułości CV liczona z pozostałych foldów
- Brak zmian protokołu, brak odrzuconych uruchomień
- Kohavi: jego „prawda” to estymata z holdoutu; nasz T daje prawdziwie niezależny punkt odniesienia — ale tylko dla danych syntetycznych

Plan do etapu 3

Zadanie	Co i jak	Koszt (dopasowania)
Dokończyć serię	zbiory D_{11}…D_{30} z tych samych ziaren; k = 2, 5, 10; oba modele	20 · 2 · 18 = 720
Dokończyć eksperyment własny	D_{11}…D_{30}, KFold(5) vs StratifiedKFold(5)	20 · 2 · 11 = 440
Rozdzielić rozmiar treningu od podziału	model na 100 / 160 / 180 obiektach z D_r oceniony na T: ile pesymizmu to sama krzywa uczenia	30 · 2 · 3 = 180
Raport 6–8 stron	obciążenie, zmienność, koszt; odtworzenie vs Kohavi; eksperyment własny; ograniczenia	—
Razem	**wykonane 580 + planowane 1340 = 1920 ≤ 2500 (budżet karty)**	

Bez zmian protokołu: ziarna, rozmiary, k, modele i metryki zostają takie jak w cvbias/protocol.py. Dodatkowe uruchomienie (rozmiar treningu) zostanie opisane jako rozszerzenie, nie zmiana.

Materiały i źródła

Oddane na etap 2

- Kod (uruchamialny): github.com/FylyppS/rozpoznawanie-wzorcow — cvbias/, run_experiment.py, make_figures_etap2.py, README z instrukcją, requirements.txt
- Pierwsze wyniki (surowe): results/etap2/ — reproduction_*.csv, own_*.csv, meta.json
- Notatka z postępów (1–2 strony): etap2/notatka-etap2.pdf
- Slajdy: etap2/slajdy-etap2.pdf; informacja o AI (załącznik 2A) jako osobny PDF w Moodle

Źródła

- R. Kohavi, A Study of Cross-Validation and Bootstrap for Accuracy Estimation and Model Selection, IJCAI 1995
- scikit-learn 1.8.0: KFold, StratifiedKFold, GaussianNB, DecisionTreeClassifier; numpy 2.4.4, scipy 1.17.1
- Karta tematu 06 i kontrakt przedmiotu (Moodle PO)